

UNIVERSIDADE FEDERAL DE SERGIPE
CENTRO DE CIÊNCIAS EXATAS E TECNOLOGIA
DEPARTAMENTO DE COMPUTAÇÃO

Qualidade de Software - 2026.2
Atividade 3
Métricas automáticas versus avaliação humana (GQM)
Equipe 04 - Cherry Studio

Adam Guilherme Mendes Lima
Enzo Emanuel Costa Maia
Douglas de Oliveira Déda
Rafael Souza Prata
Raphael Ferreira Portella Bacelar
Vinícius Morais Souza
Thayla Almeida Figueiredo

São Cristóvão, Sergipe

2026

Nota: o plano GQM, os casos, as referências, as saídas, as avaliações e os manifestos das versões A e B estão no repositório do projeto, na pasta atividade3/: [PREENCHER link do repositório]

Nota: link do vídeo da equipe (apresentação de 12/11/2026): [PREENCHER link do vídeo]

- **Resumo**

Este trabalho descreve uma comparação exploratória entre duas configurações informadas do fluxo de Base de Conhecimento do Cherry Studio 2.0.13, usando o modelo Gemini Flash-Lite Latest. Foram registradas seis perguntas em cada condição, A e B, totalizando 12 respostas. O desempenho foi comparado por F1 lexical contra referências curtas e por avaliações humanas reportadas pelo estudante. Também são descritos o versionamento, as evidências disponíveis e as limitações de reprodução.

Com `tau = 0,5`, escolhido depois das execuções, a média de F1 foi 0,479003 em A e 0,503373 em B. O sinal automático aprovou 2/6 respostas A e 3/6 B. R1 reportou 6/6 aprovações em cada versão; a concordância entre sinal automático e R1 foi 5/12. Para as quatro saídas revisadas, R1–R2 teve concordância reportada de 4/4. Esses resultados são descritivos e exploratórios: o limiar e a rubrica operacional foram formalizados depois da coleta, as fontes são sintéticas, as fichas foram reconstruídas retrospectivamente e as evidências de configuração são parciais. Não há base para afirmar que B melhorou a qualidade humana ou para recomendar adoção.

- **Introdução**

Este relatório documenta a Atividade 3 da disciplina Qualidade de Software 2026.2 (Universidade Federal de Sergipe, Departamento de Computação), realizada pela Equipe 04 sobre o Cherry Studio. A atividade compara um sinal automático (F1 lexical) com o julgamento humano sobre as respostas do fluxo de Base de Conhecimento do Cherry Studio, e registra a mudança entre duas versões do prompt desse fluxo.

A pergunta norteadora é se uma mudança simples melhora a qualidade das respostas e até que ponto a métrica automática concorda com a avaliação humana. O experimento usa seis casos, duas versões (A e B), uma execução por caso e versão (12 saídas), 12 avaliações principais (R1) e 4 segundas revisões (R2), com o mesmo aplicativo, modelo e base de documentos nas duas versões.

O relatório segue a ordem do enunciado. Cada seção abaixo tem um responsável, e a tabela a seguir indica onde cada parte do enunciado é tratada.

Bloco	Conteúdo	Parte do enunciado	Responsável
1	Plano GQM, regras fixadas antes e seis casos com referências	Partes A e B (preparação)	Raphael
2	Montagem das versões A e B e execução das 12 saídas	Parte B	Vinícius
3	F1 lexical, planilha anonimizada para os avaliadores e gráfico	Parte C	Rafael

Bloco	Conteúdo	Parte do enunciado	Responsável
4	Avaliação humana principal (R1)	Parte D	Thayla
5	Segunda revisão (R2), consenso e resultados	Partes D e E	Douglas
6	Ciclo de vida, versionamento, manifestos e diagrama	Parte F	Enzo
7	Decisão experimental, relatório, repositório e consolidação	Decisão e entregáveis	Adam

Contribuição dos integrantes

Integrante	Bloco	Tarefas e artefatos desenvolvidos
Adam Guilherme Mendes Lima (202300061868)	7 (consolidação)	Responsável por incluir o relatório final, repositório e vídeo.
Enzo Emanuel Maia Costa (202300061901)	6 (versionamento)	Preparou a documentação de ciclo de vida, manifestos, rastreabilidade e limitações após as execuções, também executou e transcreveuas respostas e assumiu tarefas de consolidação.
Douglas de Oliveira Déda (201700053097)	5 (R2, consenso e resultados)	Confirmou a revisão e avaliou posteriormente as 12 respostas. O protocolo previa revisar CT01 e CT05 em A e B; os quatro escores desse subconjunto estão transcritos e coincidem com R1 (4/4 decisões).
Rafael Souza Prata (202300061750)	3 (F1 e gráfico)	Realizou o cálculo de F1, a tabela e o gráfico foram produzidos no repositório com auxílio de IA/script local a partir das respostas e referências registrada
Raphael Ferreira Portella Bacelar (202100045822)	1 (GQM e casos)	Elaborou o plano GQM (objetivo, duas perguntas e três medidas), fixou antes das execuções o limiar tau, a rubrica, a regra de falha crítica e o critério de avanço e bloqueio, e escreveu as seis perguntas e referências dos casos (arquivos plano-gqm.md e casos.md em atividade3/).
Vinícius Morais Souza (202200060106)	2 (execução)	Executou e transcreveu as 12 respostas, dando exemplo ao longo do projeto com quatro capturas parciais (A-CT01, A-CT02, B-CT02 e B-CT04/fonte)|
Thayla Almeida Figueiredo (202300061840)	4 (R1)	Avaliadora R1,Os escores 2,2,2,0 para as 12 saídas foram organizados em registros retrospectivos e aguardam confirmação de quem avaliou posteriormente sendo o R2.

- **1- Raphael Ferreira Portella Bacelar (202100045822)**

Bloco 1: Plano GQM e preparação dos casos (Partes A e B)

Contexto do experimento

O experimento compara duas formas de instruir o mesmo fluxo de Base de Conhecimento do Cherry Studio, usando documentos de uma empresa fictícia (Cereja Eletro) sobre reembolso, garantia e entrega. A versão A usa um prompt direto, apenas com a pergunta. A versão B usa um prompt estruturado, com regras para citar a fonte e para declarar quando não há informação. O aplicativo, o modelo e os documentos são os mesmos nas duas versões, e apenas o prompt muda.

Cada versão responde a seis perguntas, o que gera 12 respostas. Cada resposta é medida de duas formas: por um sinal automático (F1 lexical, que conta palavras em comum com uma frase de referência) e por avaliação humana, com uma rubrica de 0 a 2. Em seguida, compara-se se a versão B melhora a qualidade e se o sinal automático concorda com as pessoas.

Objetivo, perguntas e medidas (GQM)

Elemento	Definição
Analisar	Duas versões do prompt do fluxo de Base de Conhecimento do Cherry Studio, A (baseline) e B.
Com o propósito de	Comparar a qualidade das respostas e verificar se um sinal automático (F1 lexical) representa a adequação avaliada por pessoas.
Do ponto de vista de	Equipe de qualidade de software.
No contexto de	Seis casos sobre a política de reembolso e a garantia da Cereja Eletro (empresa fictícia), no Cherry Studio 2.0.13, com o modelo Gemini Flash-Lite Latest.

Pergunta	Medida	Unidade	Fórmula e denominador	Limitação
Q1. A versão B atende melhor à tarefa?	M2. Taxa de aprovação humana, por versão	Proporção (x/6)	Saídas aprovadas ÷ 6. Aprovada = notas 2, 2, 2 em correção, relevância e suporte, e nenhuma falha crítica.	Só seis casos. O avaliador R1 decide sozinho 8 das 12 saídas. O cegamento é imperfeito. CT06 depende de CT01.
Q2. O sinal automático representa a adequação?	M1. F1 lexical, por saída e por versão (média e mediana)	Número de 0 a 1	P = tokens em comum ÷ tokens da resposta. R = tokens em comum ÷ tokens da referência. F1 = 2 × P × R ÷ (P + R). Sem sobreposição ou resposta vazia, F1 = 0. Média e mediana por versão sobre 6 saídas.	Mede vocabulário, não verdade. Uma paráfrase correta pode ter F1 baixo, e trocar um número por outro mantém muitas palavras e muda o fato.

Pergunta	Medida	Unidade	Fórmula e denominador	Limitação
Q2. O sinal automático representa a adequação?	M3. Concordância auto-humano	Proporção (x/12)	Saídas em que (F1 ≥ tau) coincide com a decisão humana final ÷ 12.	Depende do tau. As 12 saídas não são independentes (CT06 varia CT01, e A e B respondem às mesmas perguntas).

Regras fixadas antes da execução

As regras abaixo foram definidas e registradas em commit antes de qualquer execução, e não são alteradas depois de os resultados serem conhecidos.

Regra	Definição
Limiar (tau)	tau = 0,5. O sinal automático aprova a saída quando F1 ≥ 0,5. Valor didático previsto no enunciado, fixo e sem ajuste posterior. Justificativa: 0,5 tem leitura simples, a metade da sobreposição possível. Um limiar de 1,0 exigiria as mesmas palavras da referência, nem uma a mais, e reprovaria respostas corretas que apenas acrescentam palavras, o que impediria avaliar se o sinal representa a adequação. Sem conjunto de calibração próprio, e para evitar ajustar o limiar depois de ver os resultados, o valor foi fixado antes das execuções.
Cálculo do F1	Normalização NFC, casefold, tokens de palavras e interseção de multiconjuntos, como no código fornecido (f1_lexical.py). Resposta vazia ou falha de execução tem F1 = 0 e é registrada, sem ser descartada. Referência sem tokens: o caso é corrigido antes de rodar.
Rubrica humana	Três notas de 0 a 2 (correção, relevância e suporte) e uma marca de falha crítica de 0 ou 1, com justificativa curta e evidência. Aprovada = três notas 2 e nenhuma falha crítica.
Falha crítica	Vale 1 quando a saída: (1) afirma número, prazo, valor ou condição que contradiz a fonte e mudaria a decisão de um cliente; (2) apresenta como vigente uma informação de documento desatualizado; ou (3) responde com conteúdo inventado onde a referência pede abstenção (CT05).
Critério de avanço	A versão B é levada à próxima etapa se a aprovação humana de B for maior que a de A (x/6) e B não tiver nenhuma falha crítica.
Condição de bloqueio	Se B tiver uma ou mais falhas críticas, B não avança, e a decisão é manter A ou revisar B. Com aprovação igual ou menor e sem bloqueio, a decisão é manter A. A decisão é experimental e não autoriza produção.
Denominadores	Aprovação humana por versão: 6. Concordância auto-humano: 12. Concordância R1-R2: 4 (CT01 e CT05, nas duas versões), calculada antes do consenso.

Versões A e B e ambiente

Item	Definição
Versão A (baseline)	Prompt direto (P-CIT-01, prompts/P1-direto.md).
Versão B	Prompt estruturado, com regras de uso de fonte e de abstenção (P-CIT-02, prompts/P2-estruturado.md). É a única mudança entre A e B.

Item	Definição
Aplicativo e modelo	Cherry Studio 2.0.13 e Gemini Flash-Lite Latest, com a mesma chave e a mesma configuração nas 12 execuções.
Base de conhecimento	DOC-01 (política de reembolso v2.0), DOC-03 (FAQ de entrega) e DOC-04 (manual de garantia). O DOC-02 (versão desatualizada, conflitaria com as referências) e o DOC-05 (documento de teste de injeção) ficam de fora.
Execução	Conversa nova a cada execução, uma execução por caso e por versão.

Casos de teste

Os seis casos usam a mesma base. CT01 a CT04 são funcionais, CT05 não tem evidência suficiente na base e CT06 é uma variação de CT01. A referência de cada caso é uma frase curta escrita por pessoa a partir do trecho do documento, e foi revisada por Enzo Emanuel Maia Costa, que conferiu as seis frases contra os documentos. Nenhuma resposta de IA foi usada como referência.

Caso	Tipo	Pergunta	Fonte e trecho	Referência curta
CT01	Funcional	Qual é o prazo para desistir da compra?	DOC-01, seção 1, Direito de arrependimento	Até 7 dias corridos depois do recebimento do produto
CT02	Funcional	Em quanto tempo o reembolso é feito depois que a devolução é aprovada?	DOC-01, seção 2, Prazo do reembolso	O tempo para reembolso é de até 10 dias úteis
CT03	Funcional	Quanto tempo de garantia total têm os eletrodomésticos de linha branca?	DOC-04, Garantia legal e contratual	Os eletrodomésticos de linha branca têm 12 meses de garantia
CT04	Funcional	Quem paga o frete da devolução?	DOC-01, seção 4, Frete de devolução	O responsável pelo pagamento do frete da devolução é a Cereja Eletro
CT05	Sem evidência suficiente	Qual é o telefone da central de atendimento?	Nenhum documento da base traz telefone, só e-mail (DOC-01 e DOC-04)	Os documentos não informam o telefone da central de atendimento
CT06	Variação de CT01	Até quando posso desistir de uma compra que fiz?	DOC-01, seção 1 (mesma fonte do CT01)	Até 7 dias corridos depois do recebimento do produto

Limitações

- São apenas seis casos por versão, o que não permite concluir risco zero nem generalizar para outras bases.
- Parte das saídas é decidida por um único avaliador (R1), e o cegamento da versão é imperfeito.

- O F1 lexical mede palavras em comum, e a sua nota depende da redação da referência escrita.
- CT06 depende de CT01, então as 12 saídas não são observações independentes.
- O alias "latest" do modelo pode mudar com o tempo, o que reduz a reprodutibilidade.

Vinícius Morais Souza (202200060106)

Bloco 2: Montagem das versões A e B e execução das 12 saídas (Parte B)

Tarefa: Montar a versão A (baseline) e a versão B (muda só o prompt), com o mesmo modelo, a mesma base e a mesma versão do aplicativo. Rodar cada caso uma vez em A e uma vez em B, com conversa nova a cada execução, e guardar as 12 saídas brutas.

Registro

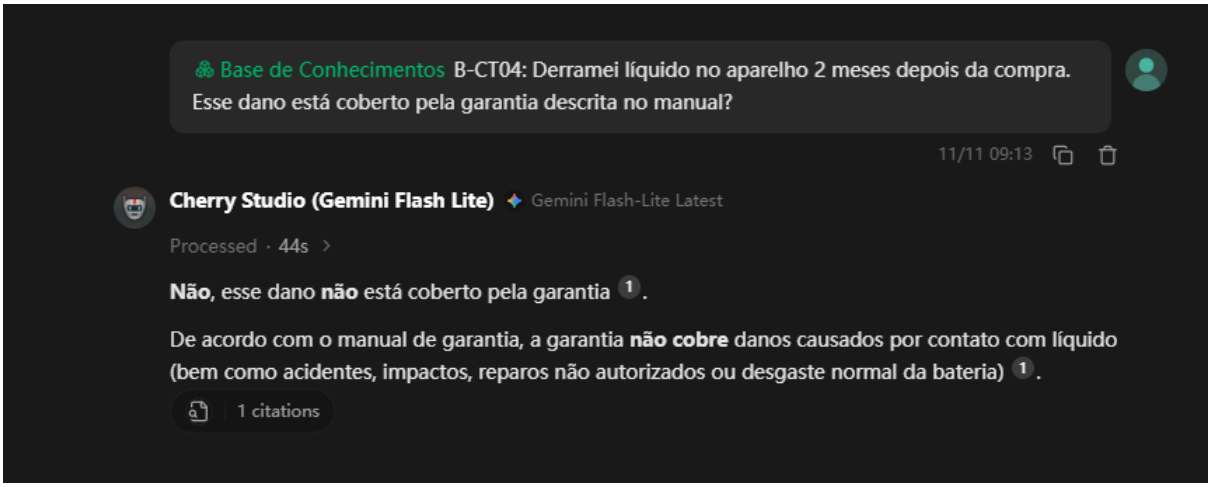
Campo	Preenchimento
Data e hora das execuções	11/11/2026 - 08:07
Versão do Cherry Studio e modelo usados	Cherry Studio 2.0.13
Configuração (chave, base ativa) igual nas 12?	Sim
Como as versões A e B foram montadas (prompt de cada uma)	CT01–CT06, uma execução por caso em cada versão
Onde estão as 12 saídas brutas e os prints	Imagens abaixo
Alguma saída vazia?	Negativo
Modelo usados	Gemini Flash-Lite Latest (`latest`, alias que não congela a revisão do modelo)
Alguma saída com erro ou truncada?	Negativo

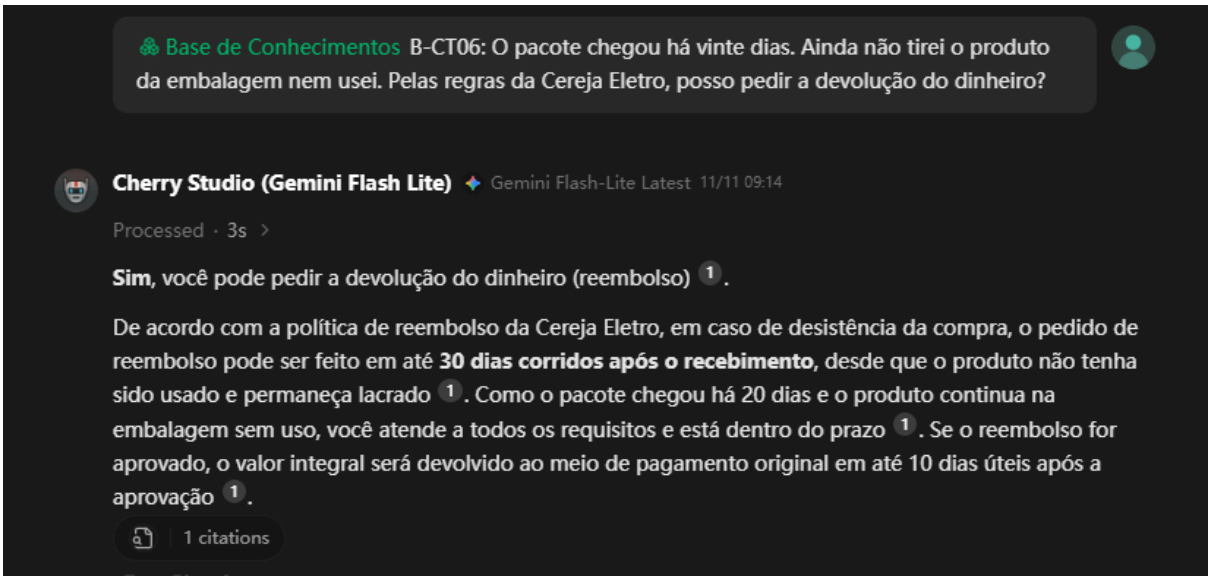
Perguntas:

- CT01,funcional,"Recebi há 20 dias um produto que continua lacrado e sem uso. Posso pedir reembolso por desistência?","Pode solicitar reembolso por desistência: o pedido foi feito dentro de 30 dias corridos e o produto está sem uso e lacrado. Se aprovado, o valor integral retorna ao meio de pagamento original em até 10 dias úteis após a aprovação.","DOC-01, regra 1 (fonte sintética; referência reescrita/revisada por pessoa, conforme relato do estudante; nome/data da revisão não informados)"

- CT02,funcional,"Meu produto foi aberto e apresentou defeito de funcionamento. Relatei o problema 5 dias corridos após recebê-lo. O que devo informar para solicitar avaliação e isso garante reembolso?",
- CT03,funcional,"Meu aparelho apresentou um defeito de fabricação 8 meses após a compra. Tenho comprovante e número de série. O que o manual prevê?
- CT04,funcional,"Derramei líquido no aparelho 2 meses depois da compra. Esse dano está coberto pela garantia descrita no manual?"
- CT05,sem evidência suficiente,"Meu aparelho parou de funcionar, mas não sei quando foi comprado, não encontrei o comprovante nem o número de série e não sei a causa do problema. Posso afirmar que está coberto pela garantia?"
- CT06,variação de CT01,"O pacote chegou há vinte dias. Ainda não tirei o produto da embalagem nem usei. Pelas regras da Cereja Eletro, posso pedir a devolução do dinheiro?"

Evidências no repositório:





- **3- Rafael Souza Prata (202300061750)**

Bloco 3: F1 lexical, anonimização e gráfico (Parte C)

Tarefa: Rodar o f1_lexical.py (ou planilha equivalente) sobre as 12 saídas, registrar P, R e F1 e o sinal automático, calcular a média e a mediana por versão, preparar a planilha anonimizada para os avaliadores e fazer o gráfico comparativo.

O cálculo foi feito pelo script local `atividade3/metricas/f1_lexical.py`, usando as respostas transcritas e as referências de `casos-e-referencias2.csv`. O script normaliza Unicode em NFC, aplica `casefold`, extrai tokens de palavras e compara as contagens como multiconjuntos.

- Precisão (P)** = tokens em comum ÷ tokens da resposta.
- Revocação (R)** = tokens em comum ÷ tokens da referência.
- F1** = 2 × P × R ÷ (P + R). Se P + R = 0, F1 = 0.
- Sinal automático** = 1 se F1 ≥ `tau`; caso contrário, 0. Nesta análise, `tau = 0,5` foi escolhido após as execuções.

Registro

Caso	P(A)	R(A)	F1(A)	Sinal A	P(B)	R(B)	F1(B)	Sinal B
CT01	0,361111	0,634146	0,460177	0	0,351351	0,634146	0,452174	0
CT02	0,449275	0,885714	0,596154	1	0,469697	0,885714	0,613861	1
CT03	0,278261	0,864865	0,421053	0	0,323232	0,864865	0,470588	0
CT04	0,309524	0,684211	0,426230	0	0,333333	0,684211	0,448276	0
CT05	0,329787	0,704545	0,449275	0	0,426471	0,659091	0,517857	1
CT06	0,366337	0,902439	0,521127	1	0,362745	0,902439	0,517483	1

Versão	F1 médio (6 respostas)	F1 mediano	Sinal automático positivo	Aprovações R1 reportadas
A	0,479003	0,454726	2/6	6/6
B	0,503373	0,494036	3/6	6/6

A concordância entre o sinal automático e a aprovação R1 reportada foi 5/12. Como R1 reportou todas as respostas aprovadas, as sete respostas abaixo do limiar são discordâncias. A-CT01 ilustra o limite do F1: R1 reportou aprovação, mas o F1 foi 0,460177, abaixo de 0,5. F1 mede sobreposição de palavras, não verdade, semântica ou suporte factual.

O CSV detalhado está em `atividade3/resultados/f1-lexical.csv`; a tabela consolidada está em `atividade3/resultados/tabela-consolidada.csv`; o gráfico está em `atividade3/resultados/grafico-resultados.svg`.

- **4- Thayla Almeida Figueiredo (202300061840)**

Bloco 4: Avaliação humana principal, R1 (Parte D)

Tarefa: Avaliar as 12 saídas às cegas com a rubrica de 0 a 2 (correção, relevância e suporte) e a marca de falha crítica de 0 ou 1, com justificativa curta e evidência, e registrar as limitações do cegamento.

Os escores reportados para cada resposta foram correção=2, relevância=2, suporte=2 e falha crítica=0. Pela regra operacional documentada posteriormente, isso corresponde a 6/6 aprovações em A e 6/6 em B. Os escores foram organizados em `atividade3/avaliacao/r1.csv` após as avaliações

Registro

Campo	Preenchimento
Tabela das 12 anotações de R1 (caso, notas, falha crítica, justificativa, evidência)	As 12 anotações estão em r1.csv. O arquivo foi organizado retrospectivamente com os escores reportados; não é a ficha original. Justificativas e evidências específicas por resposta não foram registradas.
Quantas saídas aprovadas por R1 na planilha anonimizada	2/12 no total: 6/6 em A e 6/6 em B, conforme os escores reportados para R1.
Como foi mantido o cegamento (e o que ficou visível)	Avaliação sem saber qual saída era A ou B. Os arquivos disponíveis mostram que as versões foram ocultadas e o que ficou visível durante a avaliação foram apenas o modelo e o agente escolhidos.
Limitações do cegamento	O cegamento oculta o registro contemporâneo que o comprove após o fechamento do chat. A chave de anonimização foi criada após as avaliações.
Dificuldades ao aplicar a rubrica (se houver)	Não foram relatadas dificuldades específicas.

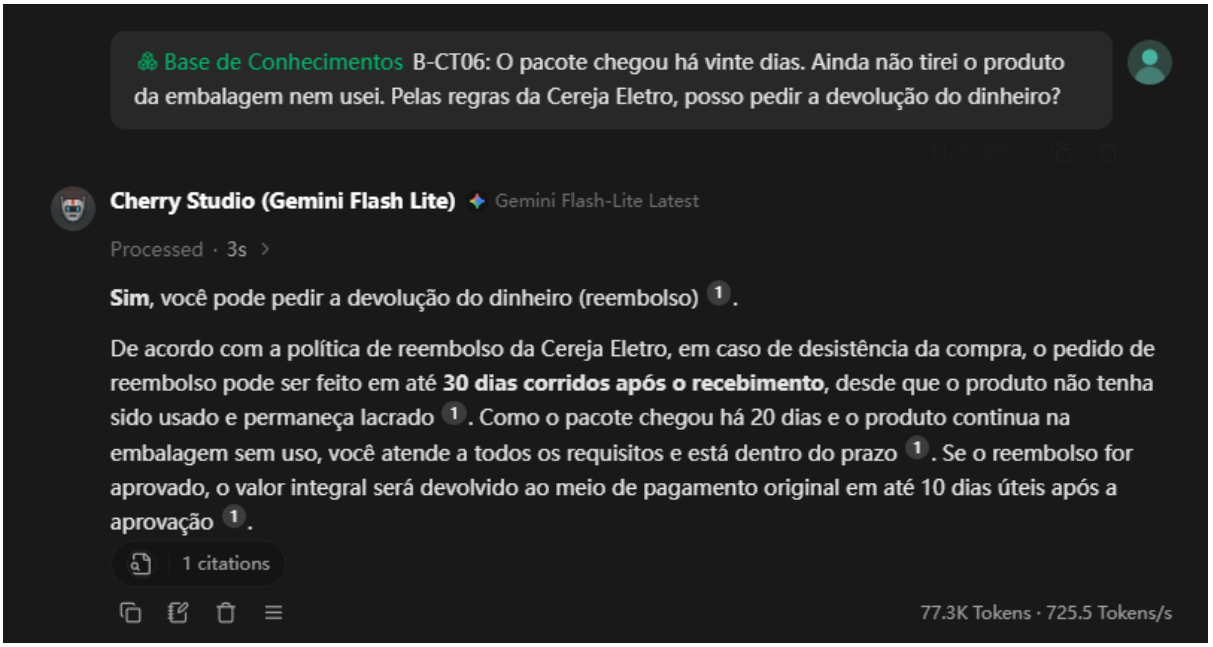
- **5- Douglas de Oliveira Déda (201700053097)**

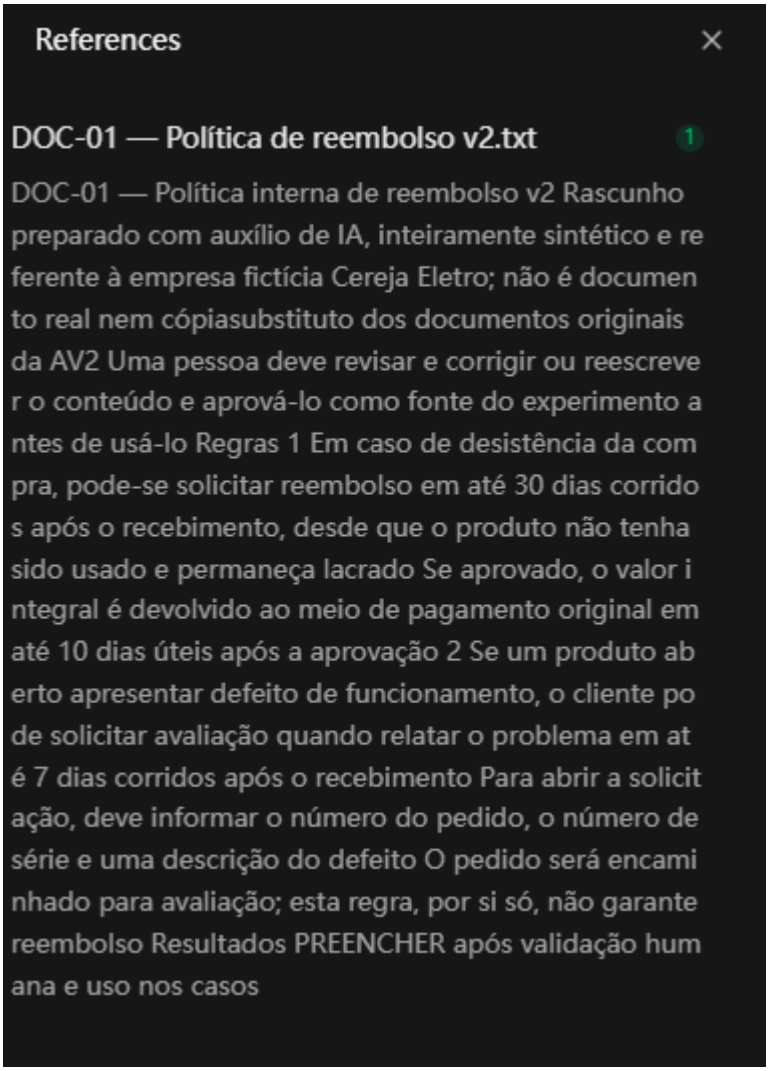
Bloco 5: Segunda revisão R2, consenso e resultados (Partes D e E)

Tarefa: Avaliar de forma independente as 4 saídas de CT01 e CT05 (A e B), calcular a concordância R1-R2 antes do consenso, registrar o consenso justificado, montar a tabela das 12 saídas, calcular os resultados por versão e analisar uma divergência ou caso-limite.

- Q1 — A versão B melhorou a qualidade humana?** R1 reportou 6/6 aprovações tanto em A quanto em B. Portanto, os dados humanos disponíveis não mostram aumento na taxa de aprovação de B. A média de F1 de B foi 0,024370 maior, mas isso é uma diferença descritiva e não demonstra melhora da qualidade.
- Q2 — O F1 representa a avaliação humana?** O sinal automático concordou com R1 em 5/12 respostas. A-CT01 mostra uma limitação: R1 aprovou a resposta, embora seu F1 tenha ficado abaixo de `tau`. Uma resposta pode ser considerada adequada por uma pessoa e ainda compartilhar poucos tokens com a referência. A conclusão é limitada pelas referências sintéticas, pelo limiar pós-hoc e pelos escores humanos retrospectivos.

As 12 saídas não são plenamente independentes: A e B respondem às mesmas perguntas e CT06 é uma variação de CT01. A concordância 4/4 de R1–R2 refere-se somente ao subconjunto com escores transcritos, não às outras oito saídas avaliadas posteriormente





- **6- Enzo Emanuel Maia Costa (202300061901)**

Bloco 6: Ciclo de vida e versionamento mínimo (Parte F)

Tarefa: Criar a pasta atividade3/ no repositório e salvar as versões A e B em commits ou pastas identificáveis (com tags), registrando a única mudança. Escrever um manifesto curto por versão e desenhar o fluxo objetivo → versão A → mudança B → execução → avaliação → decisão e acompanhamento. Fazer a abertura do vídeo.

Registro

Os manifestos registram a versão declarada do aplicativo, o modelo e os prompts informados. Os parâmetros completos e os contextos recuperados não foram preservados.
Em uma nova coleta, a equipe deve congelar e versionar A antes do teste, registrar modelo, parâmetros, base e contexto; depois alterar somente o prompt para B, criar novo commit e só então executar. Para voltar a A, desativar B, restaurar a configuração A documentada e anotar data, motivo e verificação. Não criar tags retroativas como se as configurações atuais tivessem sido congeladas antes das execuções.

Fluxo documentado:

```text
Objetivo e plano -> A (baseline) -> mudança de prompt relatada -> B
      -> 6 casos por versão -> saídas e metadados -> avaliação automática/humana
      -> decisão exploratória -> nova avaliação, monitoramento ou retorno a A
```

O fluxo liga objetivo, versões, execuções, saídas, avaliações e decisão. A rastreabilidade disponível é parcial: os prompts foram informados após as execuções, não há commits/tags A e B anteriores à coleta, e faltam capturas da configuração e dos contextos recuperados. Os manifestos estão em `atividade3/versoes/A/manifesto.md` e `atividade3/versoes/B/manifesto.md`.

- **7- Adam Guilherme Mendes Lima (202300061868)**

Bloco 7: Decisão experimental e consolidação (relatório, repositório e vídeo)

Tarefa: Escrever a decisão experimental citando o critério de avanço e a condição de bloqueio, montar o relatório em PDF, reunir o README, o checklist final, a tabela de contribuição, os slides, a declaração de IA e o VIDEO.md com o link do vídeo, revisar o repositório para não publicar chave de API nem dado sigiloso, e enviar o link do vídeo no Classroom.

Contexto: R1 reportou 6/6 aprovações em ambas as versões. B teve F1 médio numericamente maior e um sinal automático positivo a mais, mas o limiar foi escolhido após as execuções, F1 é lexical, as condições A/B não foram verificadas independentemente e as fontes/referências têm limitações de validação. R2 avaliou as 12 respostas posteriormente, mas somente os quatro escores do subconjunto inicial estão transcritos; não há cálculo de concordância para o conjunto completo.

O critério atual para uma possível etapa confirmatória foi definido pós-hoc: considerar B se sua aprovação humana não for inferior à de A e se não houver falha crítica reportada em B. Os resultados transcritos satisfazem esses limites descritivos.

Limitações:

- 1. O plano original, o commit pré-teste, o `tau` original e os critérios originais não foram anexados; `tau=0,5`, a rubrica operacional e o critério atual são pós-hoc.

- 2. DOC-01 e DOC-04 são fontes sintéticas preparadas com IA. A revisão humana das referências é relato sem nome/data; a captura B-CT04 mostra aviso de revisão pendente e campos “PREENCHER”.
- 3. Há quatro capturas parciais; nenhuma mostra os prompts completos e oito saídas não têm captura arquivada. Parâmetros e contextos recuperados não estão preservados.
- 4. Não é possível confirmar que A e B diferiram apenas no prompt; os prompts foram informados após as execuções.
- 5. O alias `latest` não congela a revisão do modelo; houve uma execução por caso/versão.
- 6. Thayla foi R1 e Douglas foi R2, conforme esclarecimento do estudante. As fichas são reconstruções retrospectivas. Douglas avaliou posteriormente todas as respostas, mas somente quatro escores R2 estão transcritos.
- 7. A chave de anonimização foi criada após as avaliações e não demonstra cegamento prévio.
- 8. Seis casos, com CT06 relacionado a CT01, não sustentam generalização nem risco zero.

- **Referências**

[GQM] van Solingen, R.; Basili, V.; Caldiera, G.; Rombach, H. D. Goal Question Metric (GQM) Approach. In: Encyclopedia of Software Engineering, 2002. https://onlinelibrary.wiley.com/doi/abs/10.1002/0471028959.sof142

[NIST] NIST. AI 600-1: Artificial Intelligence Risk Management Framework: Generative Artificial Intelligence Profile, 2024. https://nvlpubs.nist.gov/nistpubs/ai/NIST.AI.600-1.pdf

[JUDGE] Zheng, L. et al. Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena, 2023. https://arxiv.org/abs/2306.05685